Matriz de confusión

pendiente: correr evaluate.py
y compare_runs.py