FitoDiag-PY: Diagnóstico de Enfermedades Foliares en Soja, Mandioca y Sésamo mediante Transferencia de Aprendizaje

Palmira Benítez y Sebastián Villalba
Carrera, Facultad, Universidad
Ciudad, Paraguay
correo1@ejemplo.com, correo2@ejemplo.com

***Resumen*—Las enfermedades foliares causan pérdidas importantes en la soja, la mandioca y el sésamo, tres rubros clave de la agricultura paraguaya. Presentamos FitoDiag-PY, un sistema de extremo a extremo que clasifica 15 condiciones foliares de estos cultivos a partir de una fotografía tomada con un teléfono móvil. Unificamos tres conjuntos de datos públicos (XX imágenes tras la limpieza) y comparamos el ajuste fino de EfficientNet-B0 y ResNet50, con aumento de datos orientado a fotos de campo y muestreo ponderado contra el desbalance de clases. En el conjunto de prueba, EfficientNet-B0 alcanzó una exactitud de XX % y un F1 macro de XX %, con XX ms de inferencia en CPU; ResNet50 obtuvo un F1 macro de XX % con seis veces más parámetros. El modelo se expone mediante una API REST y una interfaz web, empaquetadas en contenedores Docker que se despliegan con un solo comando.**

***Index Terms*—visión por computadora, fitopatología, transferencia de aprendizaje, EfficientNet, Paraguay.**

I. Introducción y contexto

La soja es el principal producto de exportación de Paraguay: para la campaña 2025/26 se proyecta una producción récord de 12,3 millones de toneladas [1]. Su enfermedad más importante en el país es la roya asiática (*Phakopsora pachyrhizi*) [2], que puede reducir el rendimiento hasta en un 80 % si no se controla a tiempo; en enero de 2026 el SENAVE emitió una alerta fitosanitaria por esta causa [3]. La mandioca ocupa entre 160 000 y 170 000 hectáreas, con una producción cercana a 2 millones de toneladas, y es central para la agricultura familiar [4]. El sésamo es el principal rubro de renta de la agricultura familiar campesina [5]. En los tres casos, el diagnóstico depende de que un técnico recorra el lote, algo difícil de lograr a tiempo para los pequeños productores. Un error o un retraso en el diagnóstico lleva a aplicaciones tardías o innecesarias de agroquímicos.

Estado del arte. Mohanty *et al.* [6] alcanzaron 99,35 % de exactitud sobre PlantVillage, imágenes de hojas sobre fondo uniforme, pero la exactitud cayó a 31,4 % con imágenes de otras fuentes. Ferentinos [7] reportó resultados similares y la misma limitación. Por eso los trabajos recientes usan fotos de campo: el desafío iCassava [8] y su sucesor en Kaggle [9] para mandioca, y conjuntos tomados con smartphone para soja [10] y sésamo [11]. Entre las arquitecturas, ResNet [12] introdujo las conexiones residuales y EfficientNet [13] escala de forma conjunta profundidad, ancho y resolución con muchos menos parámetros. Para el desbalance, el sobremuestreo es la estrategia más efectiva en redes convolucionales [14], y el aumento de datos reduce el sobreajuste cuando hay pocas imágenes [15].

Contribución. (i) Un conjunto de datos unificado y documentado para tres cultivos relevantes en Paraguay; (ii) una comparación controlada de dos arquitecturas, con una ablación de las técnicas contra el desbalance; y (iii) un sistema desplegable con un solo comando, apto para una demostración con un celular.

Tabla I
Conjunto de datos unificado (imágenes por partición)

Cultivo	Clases	Train	Val	Test
Soja	6	XX	XX	XX
Mandioca	5	XX	XX	XX
Sésamo	4	XX	XX	XX
Total	15	XX	XX	XX

II. Metodología y arquitectura del sistema

II-A. Datos y preprocesamiento

Se combinaron tres fuentes públicas de fotos de campo: MH-SoyaHealthVision para soja (6 clases, India) [10], Cassava Leaf Disease Classification para mandioca (5 clases, Uganda) [9] y Sesame Leaf Disease para sésamo (4 clases, Bangladesh) [11]. Cada imagen se asignó a una clase `cultivo__enfermedad`. El preprocesamiento (i) descartó archivos ilegibles y duplicados exactos por hash MD5 (XX duplicados); (ii) usó solo las imágenes originales del sésamo, pues el dataset incluye copias aumentadas que filtrarían información entre particiones; (iii) limitó cada clase a 1 500 imágenes, ya que el mosaico de la mandioca concentra la mayoría de su conjunto; (iv) redimensionó el lado mayor a 512 px; y (v) dividió de forma estratificada en 70/15/15 % con semilla fija. La Tabla I resume el resultado.

II-B. Modelos y entrenamiento

Se compararon EfficientNet-B0 [13] y ResNet50 [12], ambos preentrenados en ImageNet (biblioteca timm [16]), con la misma receta: entrada de 224×224, dos épocas entrenando solo la capa de clasificación y luego hasta 15 épocas de

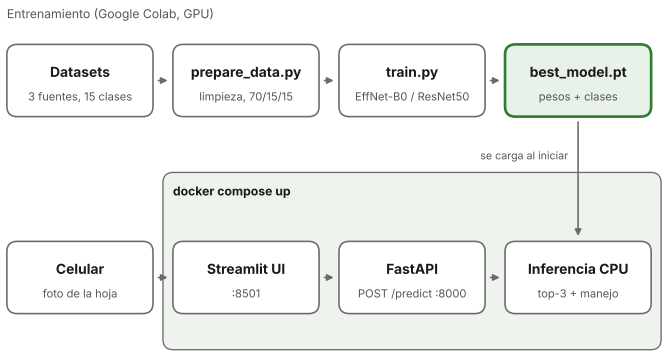


Figura 1. Arquitectura: entrenamiento fuera de línea y servicio en contenedores.

ajuste fino completo con AdamW (tasa 3×10^{-4}, decaimiento 10^{-4}), programación coseno, *label smoothing* de 0,1 y parada temprana sobre el F1 macro de validación (paciencia 5). Se entrenó en una GPU T4 de Google Colab con precisión mixta.

El aumento de datos simula fotos tomadas en el campo: recorte aleatorio (50–100 % del área), giros horizontales y verticales, rotación de $\pm 25°$, variación de brillo, contraste y saturación (± 40 %), desenfoque gaussiano y borrado aleatorio de regiones (oclusiones). Contra el desbalance se usó un muestreador ponderado con probabilidad inversa a la frecuencia de cada clase [14]. Para medir el aporte de ambas técnicas se entrenó una línea base EfficientNet-B0 sin ellas.

II-C. Métricas

Por el desbalance, la métrica principal es el F1 macro. Se reportan además la exactitud, la exactitud top-3, la tasa de cultivo equivocado (predicción de un cultivo distinto al real) y la latencia en CPU con lote de una imagen y dos hilos (media de 50 ejecuciones tras 10 de calentamiento), que corresponde al contenedor de la API.

II-D. API e interfaz

La Fig. 1 muestra la arquitectura. La API en FastAPI expone `GET /health`, `GET /classes` y `POST /predict`. Este último recibe la imagen, corrige la orientación EXIF del celular, aplica la misma transformación que la validación y devuelve la clase, la probabilidad, las tres clases más probables, una sugerencia de manejo y el tiempo de inferencia. Si la probabilidad es menor a 0,5, la respuesta indica que el modelo no está seguro y pide otra foto. La interfaz en Streamlit permite subir la foto o tomarla con la cámara desde el navegador del celular y solo se comunica con la API. Ambos servicios corren en contenedores Docker orquestados con `docker compose`; el modelo se monta como volumen de solo lectura.

III. Resultados y discusión

La Tabla II resume el desempeño en el conjunto de prueba (XX imágenes). EfficientNet-B0 obtuvo un F1 macro de XX % y ResNet50, de XX %. [Completar: cuál fue mejor y por cuánto. Si la diferencia es menor a 1 punto, decir que son equivalentes en exactitud.] En latencia, EfficientNet-B0 tardó XX ms por imagen en CPU frente a XX ms de ResNet50, con 4,0 frente a 23,5 millones de parámetros. Por esa razón se eligió EfficientNet-B0 para la API.

Tabla II
Desempeño en el conjunto de prueba

Modelo	Params (M)	Acc. (%)	$F1_{macro}$ (%)	Top-3 (%)	CPU (ms)
EfficientNet-B0	4.0	XX	XX	XX	XX
ResNet50	23.5	XX	XX	XX	XX
EffNet-B0 base†	4.0	XX	XX	XX	XX

†Sin aumento de datos ni muestreo ponderado.

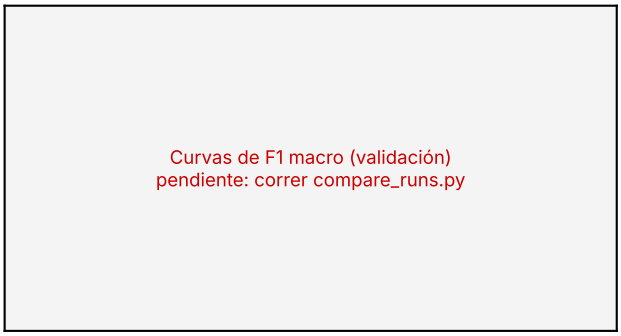


Figura 2. F1 macro de validación por época para las tres configuraciones.

La ablación mide el aporte de las técnicas contra el desbalance: sin aumento de datos ni muestreo ponderado, el F1 macro de EfficientNet-B0 fue XX %, frente a XX % con ellas. [Interpretar: si mejoraron sobre todo las clases minoritarias, mencionarlo con la clase concreta.] La Fig. 2 muestra la evolución del F1 macro de validación: las dos primeras épocas corresponden al entrenamiento de la capa de clasificación, y el salto posterior, al ajuste fino de toda la red. [Comentar en qué época se detuvo cada modelo y si la línea base muestra sobreajuste.]

Por cultivo (Tabla III), la exactitud de EfficientNet-B0 fue XX % en soja, XX % en mandioca y XX % en sésamo.

La clase con menor F1 fue XX (XX %). La matriz de confusión (Fig. 3) muestra que la mayoría de los errores ocurren dentro de un mismo cultivo: solo el XX % de las predicciones se equivocó de cultivo. [Verificar contra la figura y nombrar la confusión más frecuente, p. ej. entre dos enfermedades virales de la mandioca.] Un error de cultivo es poco probable en la práctica, porque el agricultor sabe qué cultiva; esto sugiere filtrar las clases por cultivo en la interfaz.

Estas cifras miden el desempeño con imágenes de la misma distribución que el entrenamiento. Como mostraron Mohanty *et al.* [6], el desempeño cae con fotos de otras fuentes, y ninguna imagen del conjunto proviene de Paraguay. [Si probaron con fotos propias tomadas en Paraguay, reportar aquí cuántas y cuántas acertó.] El umbral de confianza mitiga el

Tabla III
EXACTITUD POR CULTIVO EN PRUEBA (%)

Cultivo	EfficientNet-B0	ResNet50	Base†
Soja	XX	XX	XX
Mandioca	XX	XX	XX
Sésamo	XX	XX	XX
Cultivo equivocado	XX	XX	XX



Figura 3. Matriz de confusión normalizada por fila de EfficientNet-B0 en prueba. Ma: mandioca; Se: sésamo; So: soja.

riesgo: ante una foto atípica, el sistema pide otra imagen en lugar de dar un diagnóstico.

IV. CONCLUSIONES Y TRABAJO FUTURO

FitoDiag-PY demuestra que un modelo liviano como EfficientNet-B0, ajustado sobre datos públicos de campo, puede diagnosticar enfermedades foliares de tres cultivos paraguayos en XX ms por imagen sin GPU, dentro de un sistema que se despliega con un solo comando. Tres lecciones surgieron del proyecto. Primero, unificar los datos llevó más trabajo que entrenar los modelos. Segundo, los conjuntos con imágenes aumentadas de fábrica pueden inflar las métricas si no se separan antes de dividir. Tercero, con clases desbalanceadas la exactitud global oculta los errores en las clases minoritarias, por lo que conviene reportar el F1 macro.

Las limitaciones principales son la ausencia de imágenes paraguayas y dos enfermedades de la mandioca (mosaico y estría marrón) que no están reportadas en América, por lo que la API advierte al usuario si las detecta. Además, las fotos de mandioca suelen mostrar la planta entera y las de soja y sésamo una sola hoja, por lo que el modelo podría aprender el tipo de foto antes que el cultivo. Como trabajo futuro se propone (i) recolectar y etiquetar fotos en Paraguay junto con técnicos de campo; (ii) filtrar las clases según el cultivo indicado por el usuario; (iii) cuantizar el modelo para usarlo sin conexión en el celular; (iv) agregar mapas de activación (Grad-CAM) para explicar cada diagnóstico; y (v) ofrecer la interfaz en guaraní.

REFERENCIAS

[1] La Nación, “El Chaco eleva proyección de producción de soja a 12,3 millones de toneladas,” https://www.lanacion.com.py/negocios/2026/06/04/el-chaco-eleva-proyeccion-de-produccion-de-soja-a-123-millones-de-toneladas/, Jun. 2026, accedido: oct. 2026.

[2] G. A. Enciso Maldonado, A. D. Sanabria-Velázquez, J. A. Schlickmann Tank, and M. Maidana Ojeda, “Una carrera contra la pérdida de la eficacia de fungicidas: 20 años de manejo de la roya asiática de la soja en Paraguay,” *Revista Investigaciones y Estudios – UNA*, vol. 12, no. 2, pp. 59–61, 2021.

[3] La Nación, “Senave emite alerta fitosanitaria por la roya asiática y pide reforzar la defensa de cultivos,” https://www.lanacion.com.py/negocios/2026/01/26/senave-emite-alerta-fitosanitaria-por-la-roya-asiatica-y-pide-reforzar-la-defensa-de-cultivos/, Jan. 2026, accedido: oct. 2026.

[4] Última Hora, “Cultivo de mandioca repunta tras sequías,” https://www.ultimahora.com/cultivo-de-mandioca-repunta-tras-sequias, Aug. 2026, accedido: oct. 2026.

[5] La Nación, “Sésamo paraguayo se posiciona en el mercado exterior por su calidad,” https://www.lanacion.com.py/negocios/2024/09/15/sesamo-paraguayo-se-posiciona-en-el-mercado-exterior-por-su-calidad, Sep. 2024, accedido: oct. 2026.

[6] S. P. Mohanty, D. P. Hughes, and M. Salathé, “Using deep learning for image-based plant disease detection,” *Frontiers in Plant Science*, vol. 7, p. 1419, 2016.

[7] K. P. Ferentinos, “Deep learning models for plant disease detection and diagnosis,” *Computers and Electronics in Agriculture*, vol. 145, pp. 311–318, 2018.

[8] E. Mwebaze, T. Gebru, A. Frome, S. Nsumba, and J. Tusubira, “iCassava 2019 fine-grained visual categorization challenge,” arXiv:1908.02900, 2019.

[9] Makerere University AI Lab, “Cassava leaf disease classification,” Kaggle, 2020. [Online]. Available: https://www.kaggle.com/competitions/cassava-leaf-disease-classification

[10] S. Shinde and V. Attar, “MH-SoyaHealthVision: An Indian UAV and leaf image dataset for integrated crop health assessment,” Mendeley Data, V1, 2024.

[11] “Applying convolutional neural networks for early detection of diseases in sesame leaf,” Mendeley Data, V1, 2025.

[12] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.

[13] M. Tan and Q. V. Le, “EfficientNet: Rethinking model scaling for convolutional neural networks,” in *Proc. 36th Int. Conf. Machine Learning (ICML)*, ser. PMLR, vol. 97, 2019, pp. 6105–6114.

[14] M. Buda, A. Maki, and M. A. Mazurowski, “A systematic study of the class imbalance problem in convolutional neural networks,” *Neural Networks*, vol. 106, pp. 249–259, 2018.

[15] C. Shorten and T. M. Khoshgoftaar, “A survey on image data augmentation for deep learning,” *Journal of Big Data*, vol. 6, p. 60, 2019.

[16] R. Wightman, “PyTorch image models,” https://github.com/huggingface/pytorch-image-models, 2019.